

基于相对坐标控制的非均匀纹理合成方法

陈凯健, 李二强, 周漾*

(深圳大学计算机与软件学院 深圳 518060)
(zhouyangvcc@szu.edu.cn)

摘要: 针对当前非均匀纹理合成方法或无法保持非均匀纹理的大尺度结构, 或受网络结构限制, 无法合成任意大小的纹理的问题, 提出基于相对坐标控制的非均匀纹理合成方法。该方法基于全卷积金字塔结构生成对抗网络 SinGAN, 首先, 引入相对坐标信息作为条件输入进行引导控制合成, 从而保留非均匀纹理样图的整体结构特性; 然后引入旋转图块增强训练, 通过下采样和角度旋转, 获得大量纹理图块训练数据, 从而进一步提升纹理合成的细节质量。最后, 通过对多张挑战性非均匀纹理进行任意比例合成实验, 结果表明, 该方法可合成具有任意大小的新纹理样本, 合成结果能够有效地保持源图像的全局结构和局部精细纹理。此外, 用户还可根据需要选择源纹理区域进行扩展合成, 从而带来更好的可控纹理合成体验。

关键词: 非均匀纹理; 纹理合成; 可控合成; 坐标引导

中图法分类号: TP391.41 DOI: 10.3724/SP.J.1089.2023.19362

Non-Stationary Texture Synthesis Controlled by Relative Coordinate Guidance

Chen Kaijian, Li Erqiang, and Zhou Yang*

(College of Computer Science & Software Engineering, Shenzhen University, Shenzhen 518060)

Abstract: The state-of-the-art exemplar-based texture synthesis methods encounter with issues when dealing with challenging non-stationary textures. Most methods cannot preserve the global structure contained in the source texture, while some other methods cannot produce textures of arbitrary sizes due to the limitation of network architecture. In this paper, we propose a non-stationary texture synthesis method with relative coordinates as guidance. Specifically, the proposed method is built upon the pyramidal generation adversarial networks SinGAN where two key contributions are made. First, by introducing relative coordinate maps as guidance, synthesis results can well preserve the input structure; Second, by rotating texture blocks data augmentation has been done for training such that the quality of local texture details are significantly improved. Experiments show that our method can generate new samples of any size and aspect ratio, while maintaining the global structure and fine local details of source texture. Moreover, users can select to expand any part of the source texture, achieving better controllability of synthesis.

Key words: non-stationary texture; texture synthesis; controlled synthesis; coordinate guidance

收稿日期: 2021-09-13; 修回日期: 2021-10-30. 基金项目: 广东省自然科学基金面上项目(2022A1515010221). 陈凯健(1996—), 男, 硕士研究生, 主要研究方向为计算机图形学; 李二强(1994—), 男, 硕士, 主要研究方向为计算机图形学; 周漾(1986—), 男, 博士, 助理教授, 硕士生导师, 论文通信作者, 主要研究方向为纹理合成、图像处理、几何分析、三维重建.

纹理是具有重复模式的图像，纹理合成是根据输入纹理合成整体不同但局部相似的任意分辨率结果，该技术被广泛地应用于计算机建模与虚拟场景的渲染、游戏动画设计以及图像艺术风格转换等多个方面。过去 20 年中，纹理合成技术飞速发展，尤其是针对均匀纹理，如随机和近规则纹理，无论是传统的基于优化的方法^[1-3]，还是基于深度学习的方法^[4-6]，都取得了很大的成功。然而针对更具挑战性的非均匀纹理，相关研究工作不多，其合成仍然是当前的研究难点。

非均匀纹理通常指纹理模式存在空间变化的纹理^[7]，其挑战在于，这种变化往往不止像素颜色，还包括纹理元素、尺度和局部主方向的变化等，纹理合成算法难以同时捕捉这些变化。另外，非均匀纹理还往往包含一些特殊的大尺度结构，如图 1 所示孔雀羽毛纹理的扇形结构、叶片纹理

中的叶脉和木头年轮纹理的同心圆结构等。这些结构往往具备较强的语义性质，或者说这些结构本身也决定了纹理的外观属性，合成结果需要尽量保留这些大尺度结构。为此，传统方法采取的方式是引入额外的辅助通道/引导图控制合成过程，使得合成结果具备特定的大尺度结构或一定的变化趋势。如早期著名的工作 Image Analogies^[8]，可通过标注图或自然图像作为辅助引导图引导纹理合成，这种通常也叫纹理迁移。2015 年，Lukáč 等^[9]采用角度引导图的方式来合成方向性纹理。随后 Zhou 等^[7]提出自动分析非均匀纹理生成渐变引导图和方向向量场来引导合成，用户可交互式地编辑引导图来控制合成结果。然而无论是标注图还是渐变图、方向场，均是根据人为设计的特征定义的辅助通道，因此也只能控制有限种类的变化属性，表达有限的纹理模式变化。

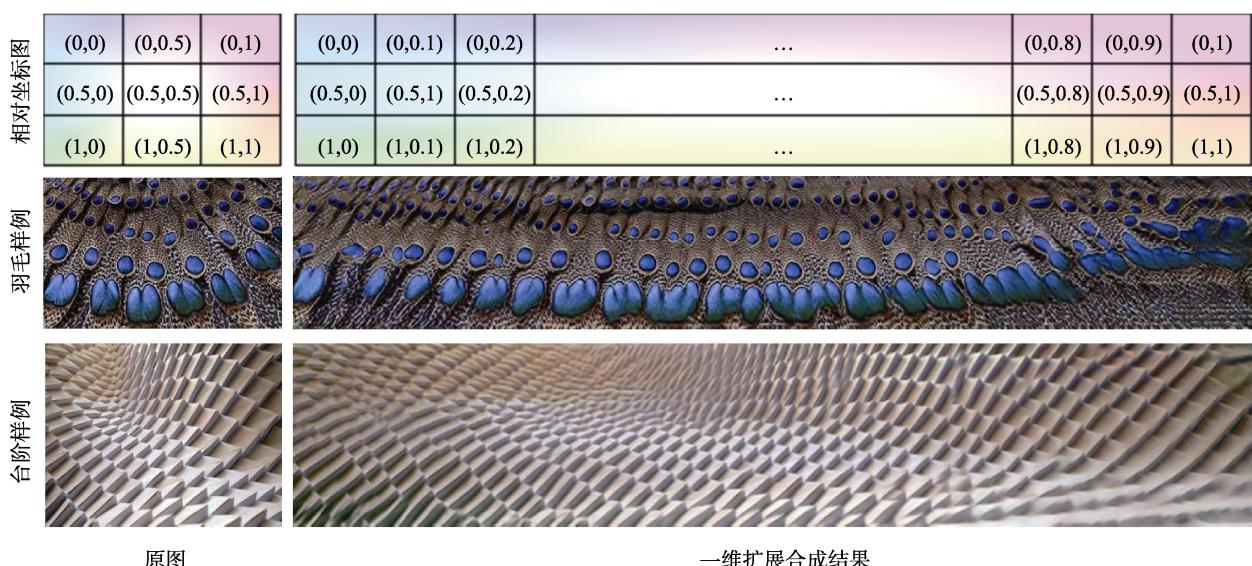


图 1 基于相对坐标控制的非均匀纹理合成流程

随着深度学习技术的发展，纹理合成技术迎来了新的发展。2018 年，Zhou 等^[10]通过单幅纹理图像上过拟合生成对抗网络，实现了非均匀纹理的扩展合成，随后又进一步将其推广至多重纹理图像的学习上^[11]。虽然合成结果质量很高，但该方法一方面受网络结构限制，只能合成输入纹理 2 倍大小的结果，不能合成任意高宽比或任意大小

的非均匀纹理，无法适应多变的纹理合成需求；另一方面，该方法也没有提供方便直观的引导图，让用户来控制合成结果。事实上，如何设计引导通道来同时捕捉非均匀纹理的渐变与大尺度结构仍然是开放性问题。

针对上述挑战，本文提出了一种利用相对坐标作为引导控制的多尺度纹理合成网络。即

在全卷积金字塔结构生成对抗网络(single natural image generative adversarial network, SinGAN)^[12]的基础上, 引入相对坐标信息作为条件输入, 将非均匀纹理的模式变化与图块相对坐标位置耦合, 从而引导控制合成, 保留纹理样图的变化趋势及其整体结构特性; 同时, 引入旋转图块训练, 通过对纹理图像进行下采样和角度旋转, 获得大量纹理图块增强数据, 以丰富输入的坐标变量信息, 进一步提高纹理合成的细节质量。本文方法最终可合成具有显著多样性的任意大小和高宽比的新纹理样本, 合成结果有效地保持了训练图像的全局结构和精细纹理, 为用户提供更好的纹理控制合成体验。

1 相关工作

基于样例的纹理合成已经具有 20 多年的历史, 根据纹理模式是否存在空域变化, 可以将纹理图像大致分为均匀纹理和非均匀纹理两类。前者主要包含随机纹理和近规则纹理。针对均匀纹理, 传统方法从基于像素的优化方法^[13-15], 到基于图块^[16-18]和基于全局目标函数的优化^[1-3], 取得了很大进展。然而针对极具挑战性的非均匀纹理, 由于纹理模式的空域变化和其包含的大尺度语义结构, 只有能合理地控制合成结果的模式分布, 才能使最终结果保持样例的变化趋势或大尺度结构, 而这通常需要借助额外的辅助引导通道, 如自然图像、语义标注图、边缘结构图以及方向场等。下面将从可控纹理合成的角度对国内外现状进行详细分析。

早期可控纹理合成更多的是纹理迁移。Efros 等^[16]首先提出这一概念, 其提出的 Image Quilting 算法可以在进行候选纹理块选择的过程中加入引导图的颜色或边缘特征约束, 从而让拼合的纹理图像符合引导图的大尺度结构或颜色分布。Hertzmann 等^[8]拓展了纹理迁移的范畴, 提出了影响深远的图像类比, 最近火热的神经风格迁移从某种意义上源自该思想。2018 年, Men 等

^[19]针对语义标注图信息过少引发合成歧义性的问题, 引入多个动态项引导合成过程, 包括显著性结构信息和轮廓匹配等, 显著地提高了基于标注图控制的纹理合成效果。总之, 虽然标注图简单明了, 但是想要获得精确的语义标注以及绘制目标语义标注, 本身就需要大量繁琐的交互, 加上纹理优化合成速度缓慢, 这些方法的实际应用仍然困难重重。

上述方法仅针对均匀纹理或复合纹理。针对非均匀纹理, 早期工作也是利用控制图来辅助合成^[20-23]。其中的目标纹理的控制图均是由用户手动提供, 或者来自三维表面的纹理模型上^[22]。2015 年, Lukáč 等^[9]采用用户手绘角度引导图的方式来控制合成方向性非均匀纹理。2016 年, Lockerman 等^[24]提出一种纹理图像多尺度语义自动分割方法, 但仅针对复合纹理, 而不是非均匀纹理。对此, Zhou 等^[7]于 2017 年提出了一种非均匀纹理渐变分析方法, 用单值渐变通道表达纹理模式的空间分布, 用无朝向向量场表达局部模式主方向变化, 从而达到精确控制非均匀纹理合成结果的空间分布与方向变化的目的。

然而这些传统的基于优化的纹理合成方法, 一方面受限于算法本身的低效率, 在优化纹理的同时还要考虑引导图提供的约束项, 合成过程十分缓慢, 无法实现实时可控合成; 另一方面, 标注图、渐变图和向量场等辅助通道, 均只能表达非均匀纹理某一方面变化, 如何直观地编码非均匀纹理的模式渐变与大尺度结构, 仍然是当前纹理合成的一大挑战。

随着深度学习、生成对抗网络等的发展, 可控纹理合成也有了新的进展。2018 年, Zhou 等^[10]基于生成对抗网络, 通过在单幅纹理图像上过拟合训练, 促使网络学习从小纹理块扩展成包含其大纹理块的映射, 最终网络在学习纹理模式内在分布的同时, 还能使得输出结果符合输入纹理的结构, 一举解决了非均匀纹理合成的难题。该方法成功的本质原因是其输入的小

纹理实际被网络当作结构引导,使得输出结果同时保持了纹理渐变趋势及其大尺度结构。当输入纹理换成其他纹理或者自然图像时,该方法将获得纹理迁移结果。然而该方法只能对纹理进行二维的扩展合成,若要对非均匀纹理进行单一维度(即纹理图像只进行水平或竖直方向的扩展,如图 1 所示)的扩展合成,则无法取得高质量的结果,一种可以合成具有任意大小和比例图像的网络模型亟待提出。2020 年,Shocher 等^[25]和 Shaham 等^[12]分别提出在单幅自然图像上过拟合训练的 InGAN 和 SinGAN,其中前者用于自然图像重定向任务,后者从单幅自然图像中学习非条件生成模型,这 2 种方法也能用于非均匀纹理图像合成,且能够合成任意大小的纹理结果。尤其是 SinGAN,它是一个金字塔型全卷积对抗生成网络结构,不同尺度图像的分布信息由每层的对抗生成网络来负责学习。虽然 SinGAN 的合成结果获得了惊人的细节质量,但是在非均匀纹理合成中却无法保留纹理的整体结构,本文后面实验部分将进一步与这些工作进行对比。考虑多尺度合成在传统纹理优化中的杰出表现,本文方法直接借鉴了 SinGAN 这一多尺度生成结构。

除了纹理合成,深度学习也深刻地影响了自然图像可控合成,如基于标注图进行条件生成的 SPADE^[26], CoCoGAN^[27]和基于草图的 TextureGAN^[28]等。CocoGAN^[29]是与本文最为相关的,其同样采用了相对坐标图作为条件输入生成局部图块,并将再拼接图块作为最终的生成结果。本文也引入了相对坐标作为控制条件,但与 CocoGAN 存在 2 个主要区别:一是 CocoGAN 需要在大数据集上训练,而本文仍然是对单幅纹理图像进行过拟合;二是 CocoGAN 的训练在基于局部坐标生成图块后,需要先拼接成合理的图像再送入判别器判别;而本文方法考虑纹理图像本身特性,即纹理图块间存在高度相似性,本文的训练不需要进行坐标拼接,可直接对图块进行合成训练。

2 本文方法

基于多尺度生成网络 SinGAN^[12],本文提出的适合非均匀纹理合成的方法,包含 2 个方面:一方面为合理引导合成过程,引入相对坐标控制图作为条件输入。如前文所述,要简单而直观地表达非均匀纹理的变化及其大尺度结构是一件非常困难的事情。对此,本文提出直接将纹理局部模式与其空间位置信息进行耦合,从而无需基于人为定义特征提取或制作语义标注图、方向场等辅助通道。相对坐标控制图的制作十分简单,即将源纹理图像所有像素坐标归一化到 [0,1],再将归一化后的像素坐标视为相对坐标图,即可将其直接合并到像素特征通道作为网络的条件输入。另一方面,考虑训练完成后测试阶段用户输入的目标条件(即相对坐标图)可能与源纹理相对坐标不同,本文引入旋转图块的重建及生成训练,通过对源纹理及相应的坐标信息进行旋转图块的裁剪,获得训练样本,结合相对坐标条件输入和旋转图块训练,最终实现可控的纹理合成。实验表明,旋转图块增强训练,能显著地提高纹理合成,尤其是扩展合成的能力。下面将详细介绍本文模型的网络结构、网络测试、训练细节与损失函数。

2.1 网络架构

本文方法采用如图 2 所示多尺度生成网络结构,由粗到精地进行基于相对坐标图的可控纹理合成。其中,每层生成网络负责根据输入坐标图隐含的纹理结构信息,对上层纹理结果进行当前尺度下的纹理精细化合成。为实现以上目的,各层网络采用 Patch-GANs^[30]架构,并在判别器中额外增加相对坐标图条件输入,约束输出结果与相对坐标图的对应关系,使得合成结果更好地保留了输入区域的整体变化趋势及大尺度结构。

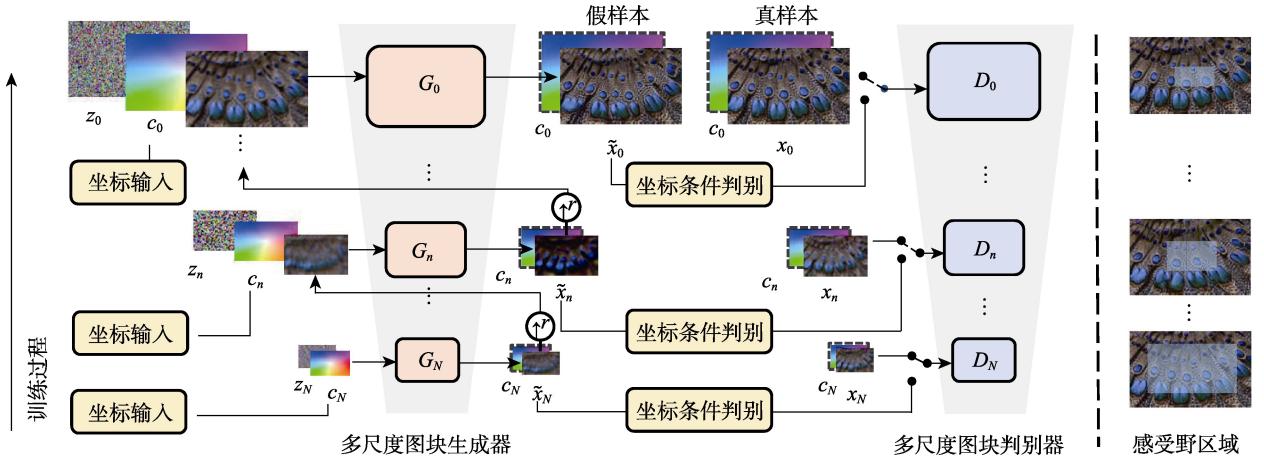


图 2 本文方法整体结构

在多尺度生成网络中, 不同尺度的生成网络负责的内容不同。在最大尺度 N 中, 生成网络 G_N 负责生成图像全局结构的总体布局, 将相对坐标信息 c_N 和空间高斯噪声 z_N 映射到多样化的纹理样本图像 \tilde{x}_N 上, 即 $\tilde{x}_N = G_N(z_N, c_N)$ 。而其他尺度生成网络 $G_n (n < N)$ 负责根据相对坐标图 c_n 和高斯噪声 z_n , 为上层网络输出的上采样版本 $(\tilde{x}_{n+1})^{\uparrow r}$ 添加当前尺度的纹理细节, 即

$$\tilde{x}_n = G_n(z_n, c_n, (\tilde{x}_{n+1})^{\uparrow r}).$$

各尺度的生成网络具有相同的网络结构, 如图 3 所示。其中, 生成器 G_n 包含残差分支及跳跃分支, 残差分支将上一尺度 \tilde{x}_{n+1} 的上采样版本 $(\tilde{x}_{n+1})^{\uparrow r}$ 与噪声图 z_n 之和以及相对坐标图 c_n 作为输入, 以级联的形式送入 5 个卷积层 ψ_n , 输出一个残差图像。最后, 生成器 G_n 将残差图像与跳跃分支 $(\tilde{x}_{n+1})^{\uparrow r}$ 结合, 输出生成图像

$$\tilde{x}_n = (\tilde{x}_{n+1})^{\uparrow r} + \psi_n(c_n, z_n + (\tilde{x}_{n+1})^{\uparrow r}).$$

当 $n = N$ 时, $(\tilde{x}_{n+1})^{\uparrow r}$ 为全 0 组成的图像。

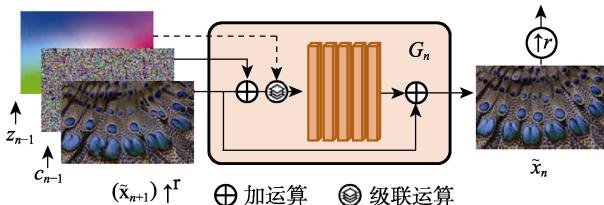


图 3 单尺度的生成网络结构

2.2 网络测试

网络测试时, 多尺度生成网络以相对坐标

图 c_0 为输入, 输出符合该区域内全局变化趋势及局部细节的纹理图像。首先将相对坐标图 $\{c_N, \dots, c_0\}$, 并产生相同分辨率的高斯噪声 $\{z_N, \dots, z_0\}$ 作为整体外部输入。其次, 网络中最大尺度生成器 G_N 以 (z_N, c_N) 为输入, 生成与输入区域纹理分布一致的低分辨率纹理输出 \tilde{x}_N 。后续生成器 $\{G_{N-1}, \dots, G_0\}$ 则以当前层坐标图、高斯噪声及上采样版本的上层纹理输出为输入, 依次进行纹理细化, 获得分辨率由低到高的纹理结果。

当用户需要进行控制合成, 如基于局部坐标合成或者任意尺寸合成时, 仅需指定区域、变形维度及变形大小, 裁剪相对坐标图 c_0 并采样对应双线性后将其输入网络, 即可生成带有原区域全局变化趋势及局部纹理细节的任意尺寸纹理。

2.3 训练细节和损失函数

本文方法中的多尺度网络架构采用逐层渐进训练方式, 即从第 N 层到第 0 层逐层训练, 第 n 层的生成网络训练需要参数固定的生成器 $\{G_N, \dots, G_{n+1}\}$ 、高斯噪声 $\{z_N, \dots, z_{n+1}\}$ 及相对坐标图 $\{c_N, \dots, c_{n+1}\}$ 提供上层尺度结果, 结合当前尺度噪声及相对坐标图进行纹理样本的重建及生成训练。其中, 重建训练将固定一组随机噪声及坐标输入映射到原坐标区域, 生成训练将随机噪声及坐标输入映射到带有原坐标区域纹理趋

势的结果.

在每层的训练过程中, 目标样本由当前尺度下的纹理源图及旋转图块组成. 首先, 如 SinGAN 训练策略, 本文使用当前尺度下的纹理源图作为目标样本, 训练网络正向纹理的重建及生成能力. 此外, 考虑训练完成后测试阶段用户输入的目标条件(即相对坐标图)可能与源纹理相对坐标不同, 本文引入旋转图块的重建及生成训练, 以增强网络纹理合成、尤其是扩展合成的能力.

2.3.1 旋转图块训练

非均匀纹理因其纹理元素在空间域上了兼具方向、颜色和大小的变化, 仅使用正向的纹理图块作为模型的训练样本, 难以令模型学到正确的相对坐标图及原纹理的结构相关性.

为了提高合成纹理的细节质量, 本文引入旋转图块训练作为数据增强, 以目标图像的局部相对坐标图作为条件输入, 重建与生成对应区域的纹理. 图 4 展示了旋转图块的获取及训练过程, 其中, 本文通过对源图及相应坐标图进行旋转图块的裁剪, 获得局部相对坐标图输入及对应的纹理输出. 后文消融实验部分证明, 该数据增强方式有效提升纹理的细节质量, 可以进一步保留纹理合成结果的全局整体结构及局部纹理细节信息.

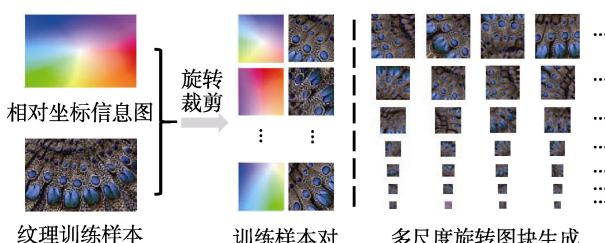


图 4 训练图块获取及多尺度图块生成与重建训练

2.3.2 损失函数

本文方法中的多尺度网络架构每层都包括生成及重建训练, 分别对对应抗损失与重建损失, 总损失可表示为

$$\min_{G_n} \max_{D_n} (L_{\text{adv}}(G_n, D_n) + \alpha L_{\text{rec}}(G_n)) \quad (1)$$

由于源图与旋转图块训练损失一致, 文中仅详细介绍源图训练损失.

(1) 对抗损失 L_{adv} . L_{adv} 作为生成训练的损失, 约束随机噪声生成结果的所有局部区域尽可能真实, 同时与输入坐标图隐含的全局变化一致. 本文方法采用 PatchGANs^[30]及 WGAN-GP 损失^[31], 将输入样本各局部区域的判别分数均值作为最终判别分数.

(2) 重建损失 L_{rec} . L_{rec} 作为重建训练的损失, 保证一组特定的噪声可映射到第 n 个尺度的原纹理图 x_n , 以便后续编辑使用. 在 x_n 的重建过程中, 本文方法首先将各层噪声输入 $\{z_1^{\text{rec}}, \dots, z_n^{\text{rec}}\}$ 设置为 $\{z^*, 0, \dots, 0\}$, 其中 z^* 是一组固定的噪声映射. 其次, 方法显式地要求该组噪声映射生成的结果 \tilde{x}_n^{rec} 尽可能与训练样本 x_n 本身相似. 对于 $n = N$, 重建损失使用

$$L_{\text{rec}} = \|G_n(z_n^*, c_n) - x_n\|^2 \quad (2)$$

其中, z_n^* 表示第 1 层固定随机噪声. 而对于 $n < N$, \tilde{x}_n^{rec} 由 $\tilde{x}_{n+1}^{\text{rec}}$ 的上采样版本、相对坐标图及全 0 噪声生成, 重建损失使用

$$L_{\text{rec}} = \|G_n((\tilde{x}_{n+1}^{\text{rec}})^{\uparrow r}, c_n) - x_n\|^2 \quad (3)$$

3 实验结果与分析

3.1 实验配置

本文方法采用 Python 及深度学习框架 PyTorch 实现, 运行环境包括 Intel Xeon E5-2630 v3 CPU, NVIDIA Titan Xp (12 GB) GPU, 256 GB 内存及 Linux 操作系统.

3.2 实验结果展示

本文从 Zhou 等^[10]发布的非均匀纹理数据集中, 选择了 3 幅极具挑战的非均匀纹理图像进行网络训练及测试, 其结果如图 5~图 7 所示, 其中, 每个图的左上角为对本文方法对纹理本源图进行重建的结果, 右上角为对纹理样图进行横向单一维度 2 倍的扩展结果, 左下角为对纹理样图纵向单一维度 2 倍的合成结果, 右下角为对

纹理样图进行二维的扩展合成结果。通过观察可以发现, 本文方法的扩展合成结果保留了源纹理的全局变化趋势与局部纹理, 合成结果真实、自然。



图 5 本文对砖块纹理进行多维度扩展合成的结果

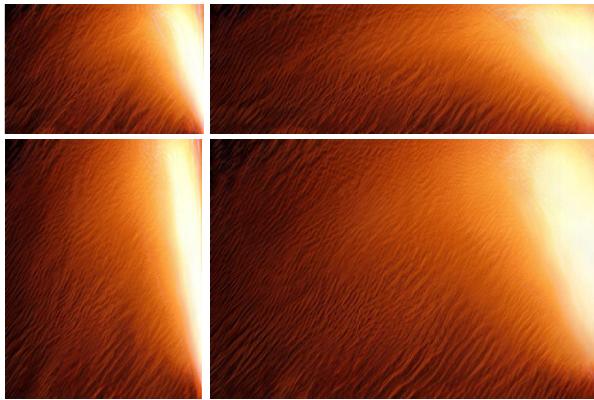


图 6 本文对光束纹理进行多维度扩展合成的结果

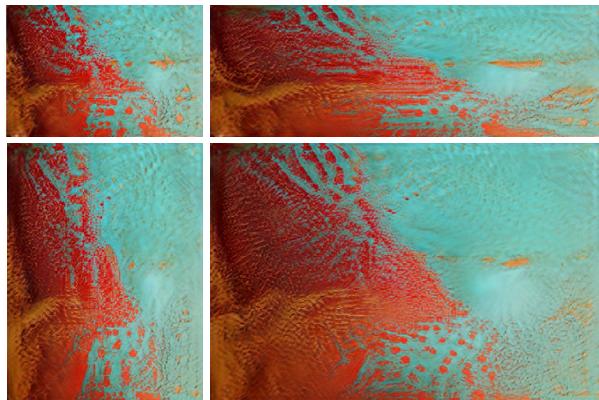


图 7 本文对颜料纹理进行多维度扩展合成的结果

3.3 方法对比

为与现有先进工作进行对比分析, 本文选择了 Zhou 等^[10]提出的非均匀纹理扩展合成方法, 以及 InGAN^[25]和 SinGAN^[12]进行非均匀纹理的多

维度扩展合成对比。与本文方法相似, 这些方法都是基于单幅图像进行过拟合训练, 且具备非均匀纹理扩展合成能力。其中, 由于 Zhou 等^[10]方法只能对输入纹理进行二维的 2 倍扩展合成, 为获得一维扩展合成结果, 本文对其采用了将输入纹理进行拉伸再二维扩展的策略, 即将输入纹理待扩展维度分辨率保持不变、其他维度缩放减半, 再输入其网络, 从而获得单一维度扩展合成结果。

图 8~图 10 分别展示了不同方法单一横向扩展合成、单一纵向扩展合成和二维扩展合成结果对比。可以看到, 与 Zhou 等^[10]单一纹理的合成方法相比, 本文方法在单一维度扩展合成中纹理结构保留更好, 而 2 种方法的二维纹理扩展合成结果非常地相似且具有都很高的合成质量, 仅在细节上有所区别。与 InGAN^[25]相比, 本文方法合成结果全局变化更为平滑自然, 纹理细节质量更高。而对比 SinGAN^[12], 本文方法合成结果更符合输入源图的全局变化, 局部纹理更为完整, 还原效果更好。

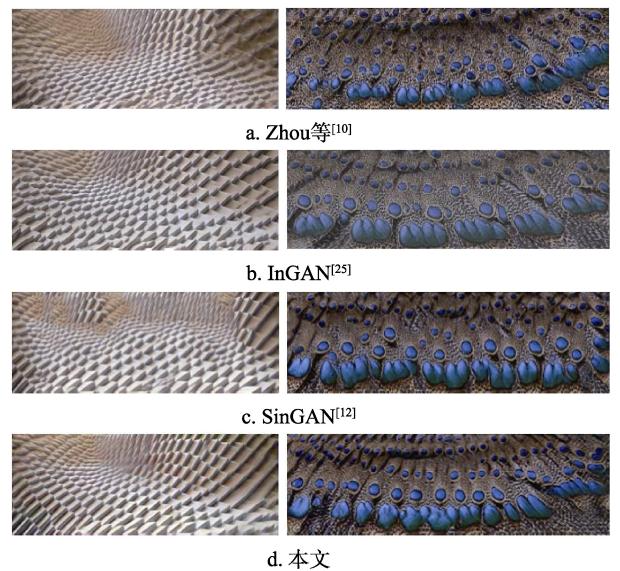


图 8 纹理横向维度 2 倍扩展合成结果对比

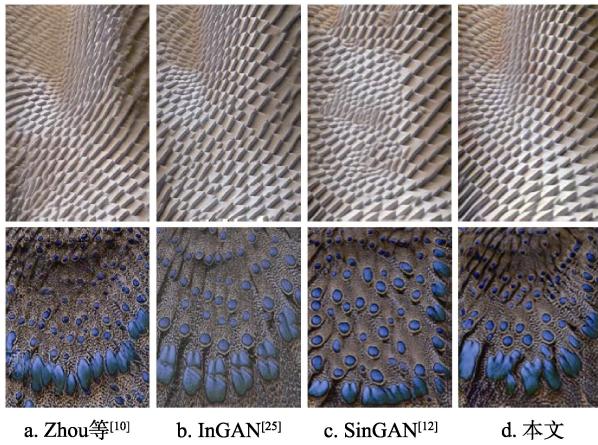


图 9 纹理纵向维度 2 倍扩展合成结果对比

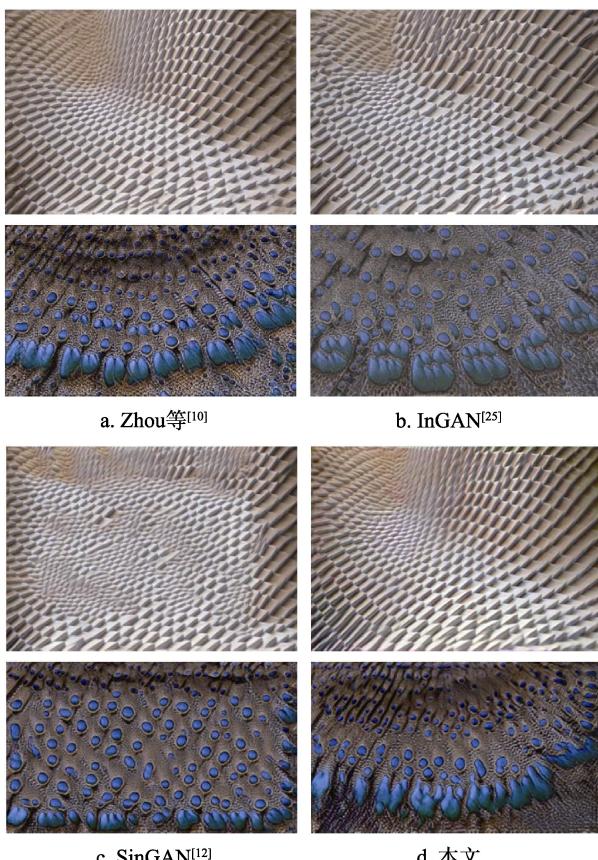


图 10 纹理横纵向二维 2 倍扩展合成结果对比

本文还进一步对比了对纹理样本进行单一维度高倍数扩展合成, 结果如图 11 所示。可以看到, 本文方法在整体纹理结构和细节质量上均优于 InGAN^[25] 和 SinGAN^[12]。

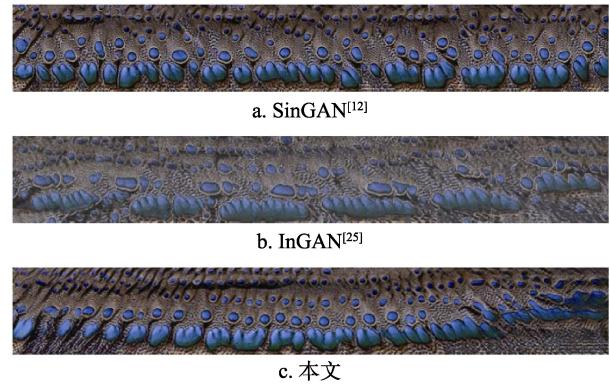


图 11 单维度 4 倍扩展合成结果对比

综合以上对比结果, 可以认为本文方法纹理合成结果的质量要优于其他 3 种对比方法。

3.4 消融实验

为了验证加入坐标信息输入和旋转图块训练的重要性, 本文进行了消融实验, 结果如图 12 所示。本文使用原始的 SinGAN^[12] 在非均匀纹理上进行训练及扩展合成, 其结果如图 12b 所示, 该结果无法很好地保留纹理源图的整体结构特性和纹理方向的连续性; 图 12c 所示为加入相对坐标图输入, 但无旋转图块训练的合成结果, 从中可以看出纹理整体结构已经符合源图, 但出现了幻影, 无法保留纹理的局部细节信息; 图 12d 所示为本文方法完整模型, 即同时加入相对坐标图输入和旋转图块训练的合成结果, 可以看出其结果在纹理元素的形态和排列上均和纹理样图保持一致, 更好地保留了源纹理的整体结构和细节信息。

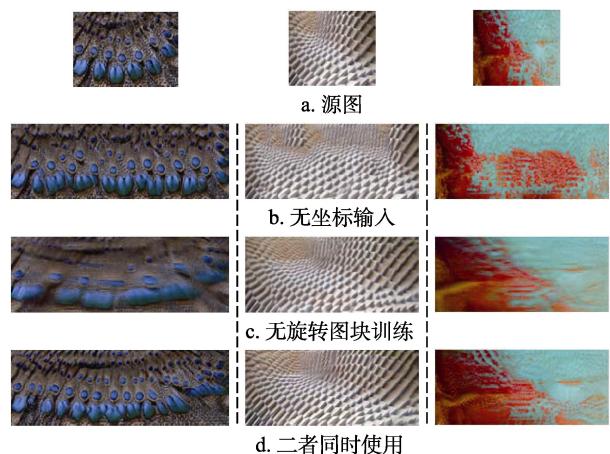


图 12 3 种纹理进行消融实验的合成结果

图 13 所示为对羽毛纹理图像的消融实验结果进行局部细节放大对比, 可以看到本文完整方法在成功保留源纹理的整体结构同时, 还大幅度提升了纹理细节质量, 得到了更优的结果.

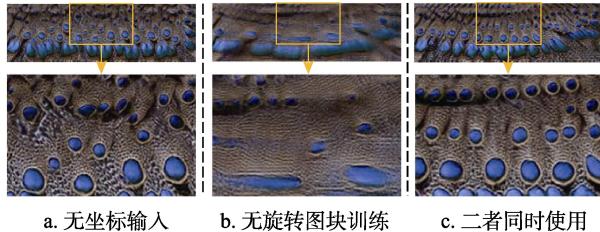


图 13 消融实验结果细节对比

通过消融实验可以对比得出: 加入坐标输入能够很好地保留纹理的整体结构, 而旋转图块训练可以进一步保留纹理合成结果的局部纹理细节信息, 提高纹理扩展合成质量, 当两者同时加入可以得到和纹理样图一致的纹理元素和整体结构, 图像的纹理整体也更真实、自然. 因

此, 坐标信息输入和旋转图块训练均是提升纹理扩展合成结果的关键, 二者缺一不可.

3.5 基于局部坐标控制的纹理合成实验

为验证本文方法具备保留局部条件区域内变化趋势的能力, 本文进行了源纹理局部扩展合成实验. 如图 14 所示, 本文从源图像中选取 4 个区域, 并从相对坐标图中裁剪出其对应的局部坐标, 二维拉伸 2 倍后输入网络; 同一组选取区域与合成结果具备相同颜色的边框. 可以看出, 本文生成结果有效地保留了局部坐标对应区域的变化趋势及纹理样式, 说明本文方法允许用户进行选择性扩展合成, 具有一定基于样例进行编辑合成的能力.

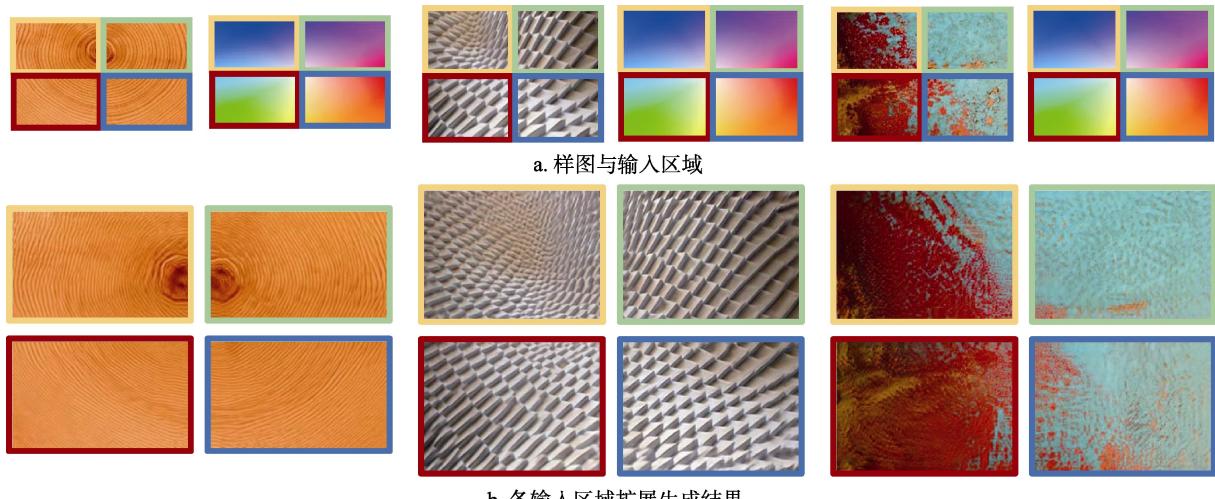


图 14 3 种纹理进行基于局部相对坐标控制的扩展结果

4 总 结

本文针对非均匀纹理合成, 首先分析了现有方法的不足, 如 Zhou 等^[10]方法只能对纹理进行二维的扩展合成, 而不能进行单一维度的扩展合成, 而其他现有模型如 InGAN^[25] 和 SinGAN^[12]等对非均匀纹理无法取得高质量合成结果. 随后, 本文基于多尺度网络 SinGAN 提出

改进思路, 引入相对坐标图作为引导对非均匀纹理进行控制合成, 从而保持纹理大尺度语义结构, 同时加入旋转纹理图块数据增强训练, 提升合成局部纹理细节. 与对比方法的定性对比结果表明, 本文方法取得了更好的合成结果, 不但可以合成任意尺寸和纵横比的纹理图像, 还允许用户选择区域进行扩展, 具备一定的纹理交互编辑能力.

然而,本文方法也存在一些不足。首先,本文方法对单幅纹理图像进行过拟合训练,所需训练时间较长,且一个模型只能用于生成一种纹理;其次,在进行类似于叶脉这种存在大尺度结构的非均匀纹理扩展合成时,本文方法存在叶脉结构细节丢失现象,如图 15 所示。但是,现有的方法均存在无法有效地保留大尺度结构的问题,本文后续工作中将针对该问题进行研究。最后,在进行合成结果对比时,本文仅进行了视觉效果对比,如何定量的评价纹理合成结果,也是未来研究方向之一。



图 15 本文方法合成叶片纹理时存在细节丢失现象

参考文献(References):

- [1] Kwatra V, Essa I, Bobick A, et al. Texture optimization for example-based synthesis[J]. ACM Transactions on Graphics, 2005, 24(3): 795-802
- [2] Barnes C, Shechtman E, Finkelstein A, et al. PatchMatch: a randomized correspondence algorithm for structural image editing[J]. ACM Transactions on Graphics, 2009, 28(3): Article No.24
- [3] Kaspar A, Neubert B, Lischinski D, et al. Self tuning texture optimization[J]. Computer Graphics Forum, 2015, 34(2): 349-359
- [4] Ulyanov D, Lebedev V, Vedaldi A, et al. Texture networks: feed-forward synthesis of textures and stylized images[C] //Proceedings of the 33rd International Conference on Machine Learning. New York: ACM Press, 2016: 1349-1357
- [5] Li C, Wand M. Precomputed real-time texture synthesis with Markovian generative adversarial networks[C] //Proceedings of European Conference on Computer Vision. Heidelberg: Springer, 2016: 702-716
- [6] Bergmann U, Jetchev N, Vollgraf R. Learning texture mani-folds with the periodic spatial GAN[C] //Proceedings of the 34th International Conference on Machine Learning. Cambridge: PMLR Press, 2017: 469-477
- [7] Zhou Y, Shi H J, Lischinski D, et al. Analysis and controlled synthesis of inhomogeneous textures[J]. Computer Graphics Forum, 2017, 36(2): 199-212
- [8] Hertzmann A, Jacobs C E, Oliver N, et al. Image analogies[C] //Proceedings of the 28th Annual Conference on Computer Graphics and Interactive Techniques. New York: ACM Press, 2001: 327-340
- [9] Lukáč M, Fišer J, Asente P, et al. Brushables: example-based edge-aware directional texture painting[J]. Computer Graphics Forum, 2015, 34(7): 257-267
- [10] Zhou Y, Zhu Z, Bai X, et al. Non-stationary texture synthesis by adversarial expansion[J]. ACM Transactions on Graphics, 2018, 37(4): Article No.49
- [11] Li E Q, Chen K J, Zhou Y. Controllable multi-texture extended synthesis and transfer[J]. Journal of Jilin University Science Edition, 2021, 59(3): 577-586
- [12] Shaham T R, Dekel T, Michaeli T. SinGan: learning a generative model from a single natural image[C] //Proceedings of the 7th IEEE International Conference on Computer Vision. Los Alamitos: IEEE Computer Society Press, 2019: 4570-4580
- [13] Efros A A, Leung T K. Texture synthesis by non-parametric sampling[C] //Proceedings of the 7th IEEE International Conference on Computer Vision. Los Alamitos: IEEE Computer Society Press, 1999: 1033-1038
- [14] Wei L Y, Levoy M. Fast texture synthesis using tree-structured vector quantization[C] //Proceedings of the 27th Annual Conference on Computer Graphics and Interactive Techniques. New York: ACM Press, 2000: 479-488
- [15] Ashikhmin M. Synthesizing natural textures[C] //Proceedings of the Symposium on Interactive 3D Graphics. New York: ACM Press, 2001: 217-226
- [16] Efros A A, Freeman W T. Image quilting for texture synthesis and transfer[C] //Proceedings of the 28th Annual Conference on Computer Graphics and Interactive Techniques. New York: ACM Press, 2001: 341-346
- [17] Kwatra V, Schödl A, Essa I, et al. Graphcut textures: image and video synthesis using graph cuts[J]. ACM Transactions on Graphics, 2003, 22(3): 277-286
- [18] Wu Q, Yu Y Z. Feature matching and deformation for texture synthesis[J]. ACM Transactions on Graphics, 2004, 23(3): 364-367
- [19] Men Y F, Lian Z H, Tang Y M, et al. A common framework for interactive texture transfer[C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2018: 6353-6362
- [20] Wang J P, Tong X, Lin S, et al. Appearance manifolds for modeling time-variant appearance of materials[J]. ACM Transactions on Graphics, 2006, 25(3): 754-761
- [21] Gu J W, Tu C I, Ramamoorthi R, et al. Time-varying surface appearance: acquisition, modeling and rendering[J]. ACM Transactions on Graphics, 2006, 25(3): 762-771
- [22] Lu J Y, Georgiadis A S, Glaser A, et al. Context-aware textures[J]. ACM Transactions on Graphics, 2007, 26(1): 3-es
- [23] Wei L Y, Han J W, Zhou K, et al. Inverse texture synthesis[J].

- ACM Transactions on Graphics, 2008, 27(3): 1-9
- [24] Lockerman Y D, Sauvage B, Allègre R, et al. Multi-scale label-map extraction for texture synthesis[J]. ACM Transactions on Graphics, 2016, 35(4): Article No.140
- [25] Shocher A, Bagon S, Isola P, et al. InGAN: capturing and remapping the “DNA” of a natural image[C] //Proceedings of the IEEE/CVF International Conference on Computer Vision. Los Alamitos: IEEE Computer Society Press, 2019: 4491-4500
- [26] Park T, Liu M Y, Wang T C, et al. Semantic image synthesis with spatially-adaptive normalization[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2019: 2332-2341
- [27] Zhang P, Zhang B, Chen D, et al. Cross-domain correspondence learning for exemplar-based image translation[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2020: 5143-5153
- [28] Xian W Q, Sangkloy P, Agrawal V, et al. TextureGAN: controlling deep image synthesis with texture patches[C] //Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2018: 8456-8465
- [29] Lin C H, Chang C C, Chen Y S, et al. COCO-GAN: generation by parts via conditional coordinating[C] //Proceedings of the IEEE/CVF International Conference on Computer Vision. Los Alamitos: IEEE Computer Society Press, 2019: 4511-4520
- [30] Isola P, Zhu J Y, Zhou T H, et al. Image-to-image translation with conditional adversarial networks[C] //Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. Los Alamitos: IEEE Computer Society Press, 2017: 1125-1134
- [31] Gulrajani I, Ahmed F, Arjovsky M, et al. Improved training of Wasserstein GANs[C] //Proceedings of the 31st Informational Conference on Neural Information Processing Systems. New York: ACM Press, 2017: 5769-5779